

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 面向零售交易数据的 K-means 聚类分析

学	号	<u>1025040818</u>
姓	名	<u>张景涛</u>
导	师	<u>指导教师</u>
专业学位类别		<u>计算机科学与技术</u>
类	型	<u>大数据分析</u>
专业（领域）		<u>计算机技术</u>
论文提交日期		<u>2026 年 5 月</u>

摘要

聚类分析是大数据分析中发现潜在结构的重要方法。传统 K-means 算法具有思想直观、每轮计算复杂度较低等优点，但在处理规模较大、噪声较多、特征分布长尾明显的交易数据时，容易受到初始中心、特征尺度和异常值的影响。本文围绕 Online Retail II 百万级零售交易数据，对 K-means 聚类方法进行完整实验研究，内容包括 Lloyd 迭代实现、K-means++ 初始化优化、数据预处理、特征工程、模型比较和聚类语义解释。

本文首先从算法层面分析 K-means 的簇内平方和目标函数、样本分配规则和中心更新规则，并比较随机初始化与 K-means++ 初始化对收敛速度和稳定性的影响。随后，针对 Online Retail II 数据集构建端到端分析流程：对原始发票行记录进行缺失值处理、异常交易过滤和长尾变量截尾；按照商品编码、年份和月份聚合生成 A4 商品月度行为特征表；根据商品描述关键词构建 A6 语义映射层；在标准化特征空间中比较 K-means、K-means++、Mini-batch K-means 和 DBSCAN 等算法。

实验结果表明，在 $K = 3$ 的设置下，K-means++ 取得最优综合表现，轮廓系数达到 0.4720，Calinski-Harabasz 指数约为 22069，Davies-Bouldin 指数约为 0.7466，说明其簇内紧凑性和簇间分离性较好。进一步结合 A6 商品关键词映射后，数值聚类结果可解释为礼品配件与包装类商品、装饰展示类商品以及描述不足的长尾商品等业务画像。本文的整理结果表明，在稳健数据清洗、合理特征构造和语义映射辅助下，K-means++ 能够为大规模零售交易数据提供有效且可解释的聚类分析框架。

关键词：大数据分析，聚类，K-means，K-means++，Mini-batch K-means，DBSCAN，零售交易数据

Abstract

Clustering is an important unsupervised method for discovering latent structures in big data. This thesis studies optimized K-means clustering for the Online Retail II transaction dataset. The work covers Lloyd’s K-means implementation, K-means++ initialization, data preprocessing, feature engineering, model comparison, and semantic interpretation of clustering results.

The proposed pipeline cleans raw invoice-line records, constructs the A4 product-month behavioral table, builds the A6 keyword-based semantic layer, standardizes numerical features, and compares K-means, K-means++, Mini-batch K-means, and DBSCAN. Experimental results show that K-means++ with $K = 3$ obtains the best overall performance, with a Silhouette score of 0.4720, a Calinski-Harabasz index of about 22069, and a Davies-Bouldin index of about 0.7466. By mapping product codes to keyword groups, numerical clusters can be translated into business profiles such as gift accessories, decorative display items, and long-tail products.

Key Words: big data analytics, clustering, K-means, K-means++, Mini-batch K-means, DBSCAN, retail transaction data

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
专用术语注释表	VII
第一章 绪论	1
1.1 研究背景	1
1.2 研究意义	1
1.3 主要研究内容	1
1.4 论文结构	2
第二章 相关工作	3
2.1 K-means 与谨慎初始化	3
2.2 大规模变体: Mini-batch K-means	3
2.3 密度聚类方法	3
2.4 聚类有效性评价与可视化	4
2.5 本章小结	4
第三章 K-means 方法与基础实验	5
3.1 问题定义与目标函数	5
3.2 Lloyd 迭代与实现细节	5
3.3 K-means++ 初始化	6
3.4 初始化方法对比	6
3.5 本章小结	6
第四章 Online Retail II 案例数据与建模流程	8
4.1 整体分析流程	8
4.2 数据集概况与质量问题	8
4.3 A4 聚合特征构建	10
4.4 A6 关键词商品语义层	10
4.5 建模设置与簇数选择	10
4.6 本章小结	11
第五章 聚类结果与业务解释	12
5.1 算法比较设置	12
5.2 定量结果分析	12
5.3 基于 A6 的商品组解释	13
5.4 面向运营的行动建议	15
5.5 本章小结	15
第六章 总结与展望	16
6.1 全文总结	16
6.2 不足之处	16
6.3 未来工作	16
6.4 本章小结	16

参考文献 17

附录 A 程序清单 18

附录 B 攻读专业学位硕士期间撰写的论文 20

附录 C 攻读专业学位硕士期间申请的专利 21

附录 D 攻读专业学位硕士期间参加的科研项目 22

插图索引

图 3.1	手写 K-means 与 scikit-learn 聚类结果对比	7
图 3.2	随机初始化与 K-means++ 在 WCSS、迭代次数和稳定性上的对比	7
图 4.1	Online Retail II 案例分析流程	9
图 4.2	基于 WCSS 和轮廓系数的簇数选择	11
图 5.1	四种聚类算法的指标对比	12
图 5.2	聚类结果的 t-SNE 可视化	13
图 5.3	聚类结果抽样 t-SNE 可视化	14
图 5.4	四种算法下 A6 商品组与聚类结果的热力映射	15

表格索引

表 3.1	不同初始化方法对比	6
表 4.1	原始数据概况	8
表 4.2	A6 中 StockCode 数量最多的前 10 类商品组	11
表 5.1	四种聚类算法定量结果	12
表 5.2	K-means++ 聚类 Top 关键词组 (A6 映射)	14

专用术语注释表

符号说明：

符号	表示含义
X	待聚类的数据矩阵
x_i	第 i 个样本向量
μ_j	第 j 个簇的聚类中心
c_i	第 i 个样本所属的簇编号
K	聚类簇数
J	K-means 目标函数，即簇内平方和

缩略词说明：

缩写	英文全称	中文译名
WCSS	Within-Cluster Sum of Squares	簇内平方和
CH	Calinski-Harabasz Index	Calinski-Harabasz 指数
DBI	Davies-Bouldin Index	Davies-Bouldin 指数
ARI	Adjusted Rand Index	调整兰德指数
t-SNE	t-Distributed Stochastic Neighbor Embedding	t 分布随机邻域嵌入

第一章 绪论

1.1 研究背景

聚类分析为无监督场景下发现数据潜在结构提供了有效方法，广泛应用于探索性数据分析、客户分群、推荐系统、异常筛查和商品运营分析等任务。在大数据环境中，交易记录通常具有体量大、噪声多、字段异构和分布长尾等特点，当人工标签缺失或标注成本较高时，无监督聚类方法能够为后续业务理解提供重要线索。

在众多聚类算法中，K-means 仍然是最常用的基线方法之一。其核心思想是通过迭代更新聚类中心，使样本到所属中心的距离平方和尽可能小。K-means 具有实现简单、计算效率较高、结果易于解释等优点，但在实际应用中也存在对初始中心敏感、对特征尺度敏感、易受异常值影响等问题。如果这些因素处理不当，算法在大规模数据集上可能表现出收敛不稳定或结果不可解释等现象。

本文依据大数据分析课程大作业内容，围绕 K-means 算法的工程实现和零售交易数据案例展开研究。一方面，从算法层面对 Lloyd 迭代过程、向量化距离计算、空簇处理和 K-means++ 初始化进行梳理；另一方面，将方法应用于 Online Retail II 百万级电子商务交易数据，形成从原始 Excel 交易记录到可解释聚类结论的完整流程。

1.2 研究意义

零售交易数据包含商品、客户、时间、价格、国家地区等多维信息。通过聚类方法可以将商品月度行为划分为若干具有相似特征的群体，帮助企业理解商品结构、识别常规销售商品和长尾商品，并为库存计划、促销组合和数据治理提供参考。与纯粹的数值建模不同，本文进一步构建商品关键词语义层，将聚类结果映射到 BAG、NECKLACE、BOX、HANGING 等商品类别，从而弥合“数值簇”和“业务含义”之间的差距。

在算法层面，本文比较随机初始化 K-means、K-means++、Mini-batch K-means 和 DBSCAN 等方法。该比较不仅展示不同算法在轮廓系数、Calinski-Harabasz 指数和 Davies-Bouldin 指数上的差异，也说明 K-means++ 在收敛速度、稳定性和解释性方面的实际优势。

1.3 主要研究内容

本文的主要研究内容包括以下几个方面：

- (1) 复现 K-means 的 Lloyd 迭代过程，分析簇内平方和目标函数、样本分配和中心更新规则；

- (2) 比较随机初始化与 K-means++ 初始化, 观察其对迭代次数、WCSS 和稳定性的影响;
- (3) 对 Online Retail II 原始交易数据进行缺失值处理、异常交易过滤和稳健截尾;
- (4) 构建 A4 商品月度聚合特征表和 A6 关键词商品语义映射层;
- (5) 使用多种内部聚类评价指标比较 K-means、K-means++、Mini-batch K-means 和 DBSCAN;
- (6) 基于 A6 映射解释 K-means++ 簇的商品构成, 并提出面向零售运营的行动建议。

1.4 论文结构

全文共分为六章。第 1 章介绍研究背景、意义和研究内容。第 2 章综述 K-means、K-means++、Mini-batch K-means、DBSCAN 以及聚类评价指标。第 3 章给出 K-means 算法原理、实现细节和初始化实验。第 4 章介绍 Online Retail II 数据集、A4 特征构建、A6 语义层和建模设置。第 5 章展示不同聚类算法的定量对比和可视化结果, 并对簇进行业务解释。第 6 章总结全文工作, 并讨论后续可扩展方向。

第二章 相关工作

2.1 K-means 与谨慎初始化

K-means 通常被表述为最小化簇内平方和 (Within-Cluster Sum of Squares, WCSS) 的问题, 并通过交替优化策略求解。每一轮迭代包括两个步骤: 首先将样本分配到最近聚类中心, 随后根据分配结果重新计算聚类中心。该过程会单调降低目标函数, 直到满足收敛条件或达到最大迭代次数^[1]。

尽管 K-means 具有较高效率, 但它对初始中心十分敏感, 可能收敛到较差的局部最优解。K-means++ 通过距离平方加权采样选择初始中心, 使后续中心更倾向于落在远离已选中心的位置, 从而提高初始中心的空间覆盖程度。理论和实践均表明, K-means++ 能够改善解的质量, 并降低收敛所需迭代次数^[2]。

2.2 大规模变体: Mini-batch K-means

在大规模数据场景下, 标准 K-means 每一轮需要扫描全部样本并计算样本到所有中心的距离, 当样本量达到百万级时, 完整批量迭代的成本较高。Mini-batch K-means 采用小批量随机样本近似更新中心, 每次只使用部分数据进行参数更新, 从而显著降低计算开销, 并支持在线或流式场景中的聚类建模^[3]。

虽然 Mini-batch K-means 通常能够获得接近标准 K-means 的结果, 但其随机小批量更新可能带来一定波动。当任务更重视聚类质量和稳定性时, 需要结合内部评价指标和可视化结果判断其是否适合作为最终模型。

2.3 密度聚类方法

DBSCAN 是一类代表性的密度聚类方法。它根据样本邻域内的点密度连接核心点, 并将低密度区域的样本标记为噪声。与中心类方法相比, DBSCAN 能够发现任意形状的簇, 对离群点具有更强鲁棒性^[4]。

然而, DBSCAN 的效果依赖邻域半径和最小样本数等参数。在高维、标准化后的零售交易特征空间中, 样本距离可能出现集中现象, 导致密度边界不够清晰。因此, 在本文案例中, DBSCAN 主要作为补充比较方法, 用于观察噪声比例和非中心类聚类效果。

2.4 聚类有效性评价与可视化

由于聚类任务通常缺少真实标签,内部评价指标成为比较模型的重要工具。轮廓系数(Silhouette)同时考虑样本与本簇的凝聚程度和与最近其他簇的分离程度,取值越高通常表示聚类效果越好^[5]。Calinski-Harabasz 指数衡量簇间离散度与簇内离散度的比值,数值越高表示簇间分离越明显^[6]。Davies-Bouldin 指数衡量簇间平均相似性,数值越低表示簇之间越容易区分^[7]。

除定量指标外,高维可视化也有助于直观检查聚类结构。t-SNE 是一种常用非线性降维方法,能够在二维空间中尽量保持样本局部邻域关系,常用于展示高维聚类结果的相对分布^[8]。本文使用 t-SNE 辅助观察不同算法生成的簇是否具有清晰边界。

2.5 本章小结

本章介绍了 K-means 及其初始化优化、大规模 Mini-batch 变体、密度聚类方法以及聚类评价指标和可视化工具。上述方法构成了后续算法实验和零售交易案例分析的理论基础。

第三章 K-means 方法与基础实验

3.1 问题定义与目标函数

给定数据集 $X = \{x_i\}_{i=1}^n$, 其中 $x_i \in \mathbb{R}^d$, K-means 将样本划分到 K 个簇中。设 $c_i \in \{1, \dots, K\}$ 表示第 i 个样本的簇编号, μ_j 表示第 j 个簇的中心, 则标准 K-means 目标是最小化簇内平方和:

$$J(C, \mu) = \sum_{i=1}^n \|x_i - \mu_{c_i}\|_2^2. \quad (3.1)$$

该目标函数是非凸的, 不同初始化可能产生不同局部最优解。因此, 本文在实验中显式控制初始化策略和停止条件, 包括最大迭代次数和中心移动阈值。

3.2 Lloyd 迭代与实现细节

经典 Lloyd 算法在样本分配和中心更新之间交替进行。在分配步骤中, 每个样本被映射到最近的聚类中心:

$$c_i = \arg \min_j \|x_i - \mu_j\|_2^2. \quad (3.2)$$

在更新步骤中, 每个中心被重新计算为对应簇内样本均值:

$$\mu_j = \frac{1}{|C_j|} \sum_{i:c_i=j} x_i. \quad (3.3)$$

上述两个步骤会不断降低目标函数 J , 直至算法收敛。

为提高距离计算效率, 可以使用欧氏距离平方的展开式:

$$\|x - \mu\|_2^2 = \|x\|_2^2 + \|\mu\|_2^2 - 2x^T \mu. \quad (3.4)$$

该式可通过矩阵乘法一次性计算一批样本到所有中心的距离, 避免在 Python 层面进行双重循环。若样本数为 n , 特征维度为 d , 簇数为 K , 朴素单轮迭代复杂度为 $O(nKd)$, 向量化实现能够显著提升吞吐量。

在二维基准数据 (V1, V2) 实验中, 本文首先进行 z-score 标准化, 以避免不同特征尺度支配欧氏距离; 随后检查缺失值, 并在出现空簇时采用重新采样或保留旧中心等策略进行修复。

3.3 K-means++ 初始化

随机初始化可能导致多个初始中心集中在同一区域，造成后续迭代调整成本较高。K-means++ 的核心思想是先均匀随机选取第一个中心，然后计算每个样本到已选中心集合的最近距离 $D(x)$ ，再按距离平方进行加权采样：

$$D(x) = \min_{\mu \in C} \|x - \mu\|_2, \quad (3.5)$$

$$P(x) = \frac{D(x)^2}{\sum_{x' \in X} D(x')^2}. \quad (3.6)$$

该策略鼓励初始中心在空间中分散分布，从而更好覆盖数据结构。选出 K 个初始中心后，算法继续执行标准 Lloyd 迭代。

3.4 初始化方法对比

本文在 xclara.csv 二维数据集上比较随机初始化和 K-means++ 初始化。评价指标包括最终 WCSS、WCSS 标准差、Lloyd 迭代次数以及多次运行之间的调整兰德指数 (Adjusted Rand Index, ARI)。结果如表3.1所示。

表 3.1 不同初始化方法对比

初始化方法	平均 WCSS	WCSS 标准差	平均迭代次数	平均 ARI
随机初始化	765.2976	0.0009	3.8	1.0
K-means++	765.2972	0.0006	2.9	1.0

由表3.1可见，两种初始化在该数据集上的最终 WCSS 非常接近，说明都能找到较稳定的聚类结构。但 K-means++ 的平均迭代次数由 3.8 降至 2.9，表明谨慎初始化能够减少后续中心调整成本。同时，两种方法的平均 ARI 均为 1.0，说明在该数据分布下聚类结果具有较高稳定性。

结合图3.1和图3.2可以进一步观察到，手写实现与库实现的聚类边界基本一致，K-means++ 在初始化阶段倾向于选择更分散的中心，因此能减少 Lloyd 迭代中的调整幅度。

3.5 本章小结

本章建立了可复现实验所需的基础实现，并展示了向量化距离计算与初始化优化的效果。这些组件为下一章的大规模零售交易数据案例提供了基础。




图 3.1 手写 K-means 与 scikit-learn 聚类结果对比




图 3.2 随机初始化与 K-means++ 在 WCSS、迭代次数和稳定性上的对比

第四章 Online Retail II 案例数据与建模流程

4.1 整体分析流程

本文将聚类方法应用于 Online Retail II 数据集，该数据集包含约 1,067,371 条交易明细记录。整体流程如图4.1所示：首先读取原始交易数据并进行缺失值、异常值和无效记录处理；随后通过特征工程构造两个关键数据集，其中 A4 用于聚类建模，A6 用于商品语义解释；接着对数值特征进行标准化，并通过肘部法和轮廓系数选择簇数；最后比较四种聚类算法，并利用 A6 语义层解释聚类结果。

4.2 数据集概况与质量问题

Online Retail II 数据集由发票行记录构成，字段包括发票编号、商品编码（StockCode）、商品描述、购买数量、交易时间、商品单价、客户编号和国家等。该数据覆盖 43 个国家、738 天交易周期，具有规模大、字段类型混合、缺失值较多和数值变量长尾明显等典型电商数据特征。

探索性统计结果如表4.1所示。数据中有 243,007 条记录缺失客户编号，占 22.77%；有 4,382 条记录缺失商品描述，占 0.41%；Quantity 字段中有 22,950 条负值记录，通常表示退货；Price 字段存在极端异常值，最小值为-53,594.36，最大值为 38,970.0。为保证距离度量的可靠性，必须在建模前处理这些问题。

表 4.1 原始数据概况

项目	数值
总记录数	1,067,371
国家数量	43
时间跨度/天	738
缺失商品描述	4,382
缺失客户编号	243,007
负数量记录	22,950
平均价格	4.6494
最小/最大价格	-53594.36 / 38970.0

本文采用“过滤-填补-截尾”的稳健策略：删除关键字段缺失记录，排除负价格和无效交易，对非关键文本字段进行保留或填补，并对数量、价格等长尾数值变量使用 $3 \times IQR$ 规则进行截尾。




图 4.1 Online Retail II 案例分析流程

4.3 A4 聚合特征构建

直接对百万级发票行记录聚类不仅计算成本较高,也容易受到重复购买和近重复交易的影响。为保留商品层面的时间结构,同时将数据转化为可建模的行为向量,本文按照 Stock-Code、InvoiceYear 和 InvoiceMonth 三个字段进行聚合,形成 A4 商品月度汇总表。A4 共包含 68,920 行、17 列,每一行对应某个商品在某个月份的行为特征。

A4 特征用于描述商品购买强度和价格动态,包括唯一发票数量、唯一描述数量、平均购买数量、单价中位数、不同客户数量、不同国家数量、不同价格数量以及价格变化事件数量等。为反映价格与数量的耦合关系,本文计算加权平均价格:

$$WA = \frac{\sum_i q_i p_i}{\sum_i q_i}, \quad (4.1)$$

其中 q_i 和 p_i 分别表示组内第 i 条记录的购买数量和单价。进一步地,本文统计低于和高于加权平均价格的金额总量,用于刻画促销和价格波动的不对称影响。

A4 中的缺失值主要集中在非数值元数据字段。例如,Description 缺失 1,323 行,占 1.92%; Customer_id_of_highest_quantity 缺失 10,651 行,占 15.45%。大部分核心数值聚合特征较完整。为适配后续建模,本文删除冗余字段,并根据字段语义对剩余缺失值进行填补或过滤。

4.4 A6 关键词商品语义层

为了使数值聚类结果能够转化为可执行的业务理解,本文构建 A6 语义层。A6 通过解析商品描述字段,并依据人工整理的关键词词典,将 StockCode 映射到商品组。例如,描述中包含 BAG、NECKLACE、BOX 等关键词的商品会被归入相应类别。A6 以商品组、商品描述和 StockCode 为核心字段,用于后验解释聚类簇的商品构成。

最终 A6 包含 6,613 条唯一记录,覆盖 336 个细粒度商品组。表4.2列出了 StockCode 数量最多的前 10 类商品组。BAG、NECKLACE 和 BOX 等类别在数据中出现频繁,说明礼品、饰品和包装相关商品是该数据集中的重要组成部分。

4.5 建模设置与簇数选择

建模前,本文删除缺失关键特征的记录,排除异常交易,并对数值变量进行稳健截尾。清洗流程保留约 59.26k 个样本,占原 A4 数据的 85.98%。随后选取十个核心数值特征,覆盖购买频率、购买数量、价格水平、客户多样性、地理分布和价格波动等维度。所有特征均使用 z-score 标准化,避免量纲差异影响欧氏距离。

簇数 K 通过肘部法和轮廓系数共同确定。图4.2显示,WCSS 随 K 增大逐渐下降,但在

表 4.2 A6 中 StockCode 数量最多的前 10 类商品组

商品组	StockCode 数量
BAG	212
NECKLACE	210
BOX	181
BRACELET	148
EARRINGS	144
HANGING	134
CANDLE	133
MIRROR	132
HOLDER	121
TILE	110

$K \approx 4$ 后下降收益明显减弱；轮廓系数在 $K = 3$ 时达到较优水平，约为 0.472。综合紧凑性、分离性和解释性，本文在后续中心类聚类比较中选取 $K = 3$ 。




图 4.2 基于 WCSS 和轮廓系数的簇数选择

4.6 本章小结

本章介绍了 Online Retail II 数据集、数据质量问题、A4 聚合特征、A6 语义映射层以及建模设置。经过清洗、聚合和标准化处理后，数据被转化为适合聚类分析且便于解释的商品月度行为矩阵。

第五章 聚类结果与业务解释

5.1 算法比较设置

本文在标准化后的 A4 特征空间中比较四种聚类算法：随机初始化 K-means、K-means++、Mini-batch K-means 和 DBSCAN。中心类算法均设置 $K = 3$ ，并重复运行以观察稳定性。评价指标包括轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数和 WCSS。图5.1展示了四种算法的指标对比。




图 5.1 四种聚类算法的指标对比

5.2 定量结果分析

四种算法的主要结果如表5.1所示。K-means++ 取得最高轮廓系数 0.4720、最高 CH 指数 22068.969 和最低 DBI 0.7466，同时 WCSS 约为 3.40×10^5 。这些结果说明 K-means++ 形成的簇具有更好的紧凑性和分离性。

表 5.1 四种聚类算法定量结果

算法	Silhouette	CH 指数	DBI	WCSS	说明
K-means++	0.472005	22068.969	0.746557	339627.060	$K = 3$
K-means	0.281377	19271.881	1.438899	359053.884	$K = 3$
Mini-batch K-means	0.265339	19154.599	1.441894	360347.706	$K = 3$
DBSCAN	0.113341	1715.338	2.619066	106137.104	噪声约 17%

与随机初始化 K-means 相比, K-means++ 在轮廓系数和 DBI 上优势明显, 说明更合理的初始中心可以帮助算法进入更好的局部最优。Mini-batch K-means 具有大规模计算优势, 但在本任务中的聚类质量略低。DBSCAN 能够识别噪声点, 但在标准化后的特征空间中分离效果有限, 轮廓系数较低且 DBI 较高。




图 5.2 聚类结果的 t-SNE 可视化

图5.2进一步表明, K-means++ 得到的簇在二维嵌入空间中边界较清晰, 簇内样本相对集中; DBSCAN 结果则更分散, 并包含较多噪声点。总体来看, K-means++ 在聚类质量和实际可操作性之间取得了较好的平衡, 是本文推荐的零售交易聚类方法。

5.3 基于 A6 的商品组解释

为了将“数值簇”转化为可执行的业务洞察, 本文将 A4 记录中的 StockCode 映射到 A6 商品组, 并统计每个簇内部商品组的频率分布。该方法能够观察聚类簇与高频高价商品、跨国销售商品、长尾描述不足商品等行为模式之间的关系。

在所有算法中, K-means++ 生成的簇最稳定且最易解释。因此, 本节重点解释 $K = 3$ 时的 K-means++ 结果。表5.2列出了每个簇中排名靠前的关键词商品组。第 0 簇中除 UNK 外, BAG、BRACELET、NECKLACE 和 BOX 占比较高, 说明该簇偏向礼品配件和包装商品。第 1 簇中 BAG、SIGN、HANGING 和 BOX 等类别较突出, 说明该簇更偏向装饰展示和主题陈列商品。第 2 簇几乎全部为 UNK, 表示该簇主要由描述不足或难以用当前关键词词典解释的长尾商品构成。

表 5.2 K-means++ 聚类 Top 关键词组（A6 映射）

簇编号	排名	商品组	占比
0	1	UNK	31.60%
0	2	BAG	2.59%
0	3	BRACELET	2.29%
0	4	NECKLACE	2.01%
0	5	BOX	1.88%
1	1	UNK	36.05%
1	2	BAG	5.10%
1	3	SIGN	3.07%
1	4	HANGING	2.65%
1	5	BOX	2.34%
2	1	UNK	100.00%



图 5.3 聚类结果抽样 t-SNE 可视化




图 5.4 四种算法下 A6 商品组与聚类结果的热力映射

图5.3展示了抽样后的 t-SNE 结果，簇之间整体分离较清晰。图5.4进一步展示了 A6 商品组在不同算法聚类结果中的热力分布，其中 K-means++ 的商品语义结构更易与业务类别对应。

5.4 面向运营的行动建议

基于聚类语义解释，可以得到三类运营建议。首先，第 0 簇包含较多礼品配件和包装类商品，这类商品可能在节日、纪念日或促销场景中被集中购买。运营上可提前进行节日备货，设计礼盒组合，并围绕送礼场景进行营销。

其次，第 1 簇偏向装饰展示类商品，如 HANGING、SIGN 和 BOX 等。这类商品可能受到季节趋势、家居装饰风格和主题陈列活动影响。运营上可结合季节主题推出新品组合，并关注陈列场景下的交叉推荐。

最后，第 2 簇 UNK 占比极高，说明其中存在较多无法被现有关键词词典准确归类的长尾商品。这类商品需要优先完善商品描述、扩展关键词词典，或进行二级聚类以发现潜在子类别。该簇不仅是商品运营对象，也是数据治理的重要入口。

5.5 本章小结

本章对四种聚类算法进行了定量比较和可视化分析，并通过 A6 语义映射将 K-means++ 的聚类结果转化为业务可解释的商品画像。结果表明，K-means++ 不仅指标表现最优，而且更容易支撑库存、营销和数据治理等运营决策。

第六章 总结与展望

6.1 全文总结

本文围绕大规模零售交易数据中的聚类分析问题，对 K-means 及其优化方法进行了系统整理和实验验证。首先，本文从算法原理出发，分析 K-means 的簇内平方和目标函数、Lloyd 交替迭代过程、向量化距离计算和 K-means++ 初始化。基础实验表明，在最终 WCSS 接近的情况下，K-means++ 能够减少平均迭代次数，提高收敛效率。

其次，本文以 Online Retail II 百万级交易数据为案例，构建了从原始数据到可解释聚类结果的端到端流程。该流程包括交易记录清洗、异常值过滤、A4 商品月度聚合特征构造、A6 关键词商品组映射、特征标准化、簇数选择和多算法比较。实验中，K-means++ 在 $K = 3$ 时取得最佳综合表现，轮廓系数为 0.4720，CH 指数约为 22069，DBI 约为 0.7466。

最后，本文通过 A6 语义层解释聚类结果，将抽象数值簇转化为礼品配件与包装、装饰展示以及长尾未知商品等业务画像。该解释方式说明，聚类分析不仅可以用于统计建模，还可以为库存计划、促销设计、商品描述治理和二次挖掘提供参考。

6.2 不足之处

本文仍存在一些不足。首先，当前特征主要来自商品月度聚合统计，尚未充分引入客户生命周期、复购率、促销活动和节假日等上下文信息。其次，A6 语义层依赖关键词词典，无法完全覆盖描述不规范或含义模糊的商品。第三，DBSCAN 参数搜索和 Mini-batch K-means 批量大小选择仍可进一步细化，以获得更充分的对比结果。

6.3 未来工作

后续可从三个方面扩展。第一，引入 Spark 等分布式计算框架，实现更大规模交易日志上的并行聚类。第二，结合自然语言处理方法从商品描述中自动抽取关键词或生成商品嵌入，提升 A6 语义层的覆盖率和准确性。第三，将聚类结果与客户价值、促销响应和库存周转等业务指标结合，形成更完整的零售智能分析闭环。

6.4 本章小结

总体而言，K-means++ 结合稳健预处理、合理特征工程和商品语义映射，能够为大规模零售交易数据提供高效、稳定且可解释的聚类分析方案。

参考文献

- [1] Lloyd S. Least squares quantization in pcm[J]. IEEE Transactions on Information Theory, 1982, 28(2): 129–137.
- [2] Arthur D, Vassilvitskii S. k-means++: The advantages of careful seeding[C]. Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms. [S.l.: s.n.], 2007: 1027–1035.
- [3] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.
- [4] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. [S.l.: s.n.], 1996: 226–231.
- [5] Rousseeuw P J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis[J]. Journal of Computational and Applied Mathematics, 1987, 20: 53–65.
- [6] Calinski T, Harabasz J. A dendrite method for cluster analysis[J]. Communications in Statistics, 1974, 3(1): 1–27.
- [7] Davies D L, Bouldin D W. A cluster separation measure[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1979, PAMI-1(2): 224–227.
- [8] van der Maaten L, Hinton G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9: 2579–2605.

附录 A 程序清单

本文程序主要包括数据读取、交易清洗、A4 聚合、A6 关键词映射、特征标准化、聚类建模和指标评价等步骤。以下代码展示核心流程，实际课程作业中可结合 Notebook 继续补充完整路径、参数搜索和可视化绘图部分。

代码 A.1 K-means++ 聚类流程示例

```
1 import pandas as pd
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.cluster import KMeans, MiniBatchKMeans, DBSCAN
4 from sklearn.metrics import silhouette_score, calinski_harabasz_score
5 from sklearn.metrics import davies_bouldin_score
6
7 raw = pd.read_excel("Online Retail II.xlsx")
8 raw = raw.dropna(subset=["StockCode", "InvoiceDate", "Quantity", "Price"])
9 raw = raw[(raw["Quantity"] > 0) & (raw["Price"] >= 0)]
10 raw["InvoiceYear"] = raw["InvoiceDate"].dt.year
11 raw["InvoiceMonth"] = raw["InvoiceDate"].dt.month
12
13 a4 = raw.groupby(["StockCode", "InvoiceYear", "InvoiceMonth"]).agg(
14     unique_invoice_counts=("Invoice", "nunique"),
15     avg_quantity=("Quantity", "mean"),
16     median_price=("Price", "median"),
17     unique_customer_counts=("Customer ID", "nunique"),
18     unique_country_counts=("Country", "nunique"),
19     distinct_price_counts=("Price", "nunique")
20 ).reset_index()
21
22 numeric_cols = [
23     "unique_invoice_counts",
24     "avg_quantity",
25     "median_price",
26     "unique_customer_counts",
27     "unique_country_counts",
28     "distinct_price_counts",
29 ]
30 X = StandardScaler().fit_transform(a4[numeric_cols])
31
32 models = {
33     "K-means++": KMeans(n_clusters=3, init="k-means++", random_state=42),
34     "K-means": KMeans(n_clusters=3, init="random", random_state=42),
35     "Mini-batch": MiniBatchKMeans(n_clusters=3, random_state=42),
```

```
36     "DBSCAN": DBSCAN(eps=0.8, min_samples=10),
37 }
38
39 for name, model in models.items():
40     labels = model.fit_predict(X)
41     valid = labels >= 0
42     print(name)
43     print("silhouette:", silhouette_score(X[valid], labels[valid]))
44     print("CH:", calinski_harabasz_score(X[valid], labels[valid]))
45     print("DBI:", davies_bouldin_score(X[valid], labels[valid]))
```

附录 B 攻读专业学位硕士期间撰写的论文

无。

附录 C 攻读专业学位硕士期间申请的专利

无。

附录 D 攻读专业学位硕士期间参加的科研项目

暂无。